




0108 Recommendation

Content Based Filtering

컨텐츠 기반 추천 (Content Based Filtering)

- 사용자가 과거에 선호한 아이템과 유사한 후보를 추천하는 기법
- 유사한 정도를 어떻게 구하느냐가 관건
- 아이템 자체의 컨텐츠 특징을 벡터화
- 벡터들간의 유사도를 계산



실습 : 컨텐츠 기반 추천



2. 컨텐츠 기반 추천

- 캐글 아마존 상품 데이터셋 다운로드
 - [karkavelrajaj/amazon-sales-dataset](https://www.kaggle.com/karkavelrajaj/amazon-sales-dataset)
 - 전처리 필요
- TF-IDF 벡터화
- 내가 좋아하는 아이템들 유사도 벡터 평균
 - 코사인 유사도
- SSD 상품 추천

Kaggle Amazon Sales Dataset



amazon.csv (4.74 MB)

Detail Compact Column 10 of 16 columns


About this file
This CSV file is having the data of 1K+ Amazon Product's Ratings and Reviews.

A product_id Product ID	A product_name Name of the Product	A category Category of the Product	A discounted_price Discounted Price of the Product	A actual_price Actual Price of the Product	A discount Percentage for the Product
1351 unique values	1337 unique values	Computers&Accessories 16% Electronics(Wearables) 5% Other (1156) 79%	₹199 4% ₹299 3% Other (1366) 93%	₹999 8% ₹499 5% Other (1274) 87%	50% 60% Other (131)
B07J8WHAJ1	Rayons Nylon Braided USB to Lightning Fast Charging and Data Sync Cable Compatible for iPhone 13, 12...	Computers&Accessories(Accessories&Peripherals)(Cables&Accessories)(Cables)(USB Cables)	₹399	₹1,099	
B09N56PVG	Anbrane Unbreakable 60W / 3A Fast	Computers&Accessories(Accessories&Peripherals)	₹199	₹349	



Term Frequency – Inverse Document Frequency

TF(단어 빈도)
이 문서 안에서 얼마나 자주 나올까?



단어가 많이 등장할수록 그 문서의 중요한 주제일 가능성이 높음



높은 빈도 = 높은 중요도




IDF(역문서 빈도)
전체 문서에서 얼마나 희귀할까?



모든 문서에 흔한 단어(예: 그리고)는 중요도가 낮게 평가




실습 : 콘텐츠 기반 추천 파이프라인




3. 추천 파이프라인 최적화

1. 상품 별 감정 분석 데이터 로드 및 전처리
2. TF-IDF 벡터화 기반 콘텐츠 추천 시스템
3. LSA 차원 축소를 통한 추천 시스템
4. PCA 주성분 분석 기반 추천 시스템
5. K-means 클러스터링을 통한 특징 공간 품질 평가
6. 종합 성능 비교 분석 및 최적 방법론 도출

AI 허브 속성기반 감정 분석 데이터



일반 감정분석 vs 속성기반 감정 분석




Latent Space Analysis

기존 추천 방식의 문제점




LSA의 해결책: 숨은 주제 찾기




K-means clustering


- 비슷한 데이터끼리 묶어주는 '비지도 학습'
- 'K' - 사용자가 정해준 군집의 개수
- 도서관 책 분류해서 서가에 정리하는 과정과 유사
- 단순 & 빠름
- 처음 중심점을 어디에 찍느냐에 따라 결과가 달라질 수 있음



파이프라인 실습 내용 정리



파이프라인 실습 의도



사용되는 주요 전처리 기법

전처리 기법	설명	비고
텍스트 통합 (Text Aggregation)	- 제품 별로 분산된 리뷰 텍스트를 하나의 통합 텍스트로 결합 - Groupby로 ProductName 별 RawText를 공백으로 연결 - 메타데이터(Domain, Category, Polarity)를 제품별로 집계	- groupby().apply(lambda x: ' '.join(x)) - 제품당 평균 리뷰 수 계산
결측치 처리 (Missing Value Imputation)	- RawText, ProductName 등의 결측값을 빈 문자열 또는 기본 값으로 대체 - GeneralPolarity를 숫자형으로 변환하고 결측값은 0으로 처리 - 속성별 감정 점수가 없는 경우 빈 Dict로 초기화	- fillna('') - pd.to_numeric(errors='coerce')
TD-IDF 벡터화 (TF-IDF Vectorization)	- 텍스트를 TF-IDF 벡터로 변환하여 수치화 - max_features=1000으로 상위 1000개 단어만 사용	TfidfVectorizer 

사용되는 주요 학습 기법

항목	설명	비고
TF-IDF (Term Frequency-Inverse Document Frequency)	- 단어의 중요도를 TF(단어 빈도) × IDF(역문서 빈도)로 계산 - 특정 문서에는 많이 나타나지만 전체 문서에는 적게 나타나는 단어에 높은 가중치 부여	- max_features=1000 - TfidfVectorizer
LSA (Latent Semantic Analysis)	- TF-IDF 행렬에 SVD(특이값 분해)를 적용하여 차원 축소 - 잠재적 의미 관계를 포착하여 동의어나 유사 개념 처리 50차원의 잠재 공간 생성	- TruncatedSVD - n_components=50
PCA (Principal Component Analysis)	- 데이터의 분산을 최대한 보존하면서 차원 축소 - 희소행렬→밀집행렬 변환 후 표준화 - 주성분들의 선형 결합으로 새로운 특징 공간 생성	- PCA - StandardScaler 

사용되는 주요 후처리 기법

항목	설명	비고
코사인 유사도 계산 (Cosine Similarity)	상품 벡터 간의 코사인 유사도를 계산하여 유사성 측정	cosine_similarity()
정렬 및 필터링 (Sorting and Filtering)	- 유사도 점수를 기준으로 내림차순 정렬 - 상위 N개 제품을 선택하여 추천 리스트 생성 - 자기 자신(추천 기준 상품)은 추천에서 제외	- argsort()[::-1] - 임계값 설정으로 품질 관리
K-means 클러스터링 품질 평가 (K-means Clustering)	- K-means를 활용해 각 특성 공간에서 클러스터 형성 - Silhouette, Calinski-Harabasz, Davies-Bouldin Score로 품질 측정	- 특성 공간의 구조적 유사성 평가 - 특성 공간의 클러스터링 정도 분석 

사용되는 주요 성능 평가 기법

항목	설명	비고
추천 다양성 (Diversity)	- 추천된 제품들의 중복 정도를 측정 - 고유 추천 제품 수 / 전체 추천 수로 계산하여 중복도 평가	$\text{unique_recommendations} / \text{total_recommendations}$
추천 속도 (Latency)	- 제품 하나당 추천 생성에 걸리는 평균 시간 측정 - 실시간 서비스 적용 가능성 평가	<code>time.time()</code> - 예측 품질 평가
클러스터링 품질 (Clustering Quality)	- Silhouette Score: 클러스터 내 응집도와 클러스터 간 분리도 (-1~1, 높을수록 좋음) - Calinski-Harabasz Score: 클러스터 간/내 분산 비율 (높을수록 좋음) - Davies-Bouldin Score: 클러스터 간 평균 유사도 (낮을수록 좋음)	$TP / (TP + FN)$ - 탐지 능력 평가
커버리지 (Coverage)	- 전체 아이템 대비 추천된 제품의 비율 - 추천 시스템이 얼마나 다양한 제품을 추천하는지 평가	$\text{unique_recommendations} / \text{len(self.products)}$



실습

3_recommendation_exp.zip

두 개의 추천 시스템 파일은 **추천 알고리즘의 기초를 다지는 실습** 파일과, **컨텐츠 기반 추천 기술을 심도 있게 비교·분석하는 개발 파이프라인** 파일로 구성되어 있습니다.

첫 번째 파일은 가장 대표적인 두 가지 추천 방식(협업 필터링, 컨텐츠 기반)을 맛보는 입문 용이며, 두 번째 파일은 텍스트(컨텐츠)를 분석하는 다양한 기법(TF-IDF, LSA, PCA)을 적용하고 성능을 비교하는 심화 과정입니다.

각 파일의 상세 기능과 셀별 설명은 다음과 같습니다.

▼ 1. **3_recommendation_exp.ipynb** (기초 예제 및 실습)

이 파일은 추천 시스템의 양대 산맥인 협업 필터링(Collaborative Filtering)과 컨텐츠 기반 필터링(Content-based Filtering)을 모두 체험해보는 **기초 실습 노트북**입니다. 라이브러리를 활용해 영화를 추천받거나, 상품 설명을 분석해 유사한 제품을 찾는 과정을 수행합니다.

• 주요 기능:

- **협업 필터링 (Collaborative Filtering):** **Surprise** 라이브러리와 MovieLens 데이터를 사용해, 사용자들의 평점 패턴을 분석하고 영화를 추천합니다.
- **컨텐츠 기반 필터링 (Content-Based):** 상품명이나 설명을 텍스트로 분석(TF-IDF)하여, 내가 보고 있는 상품과 가장 유사한 상품을 추천합니다.

순서	셀 종류	주요 내용 및 기능 설명
----	------	---------------

0	Markdown	노트북 소개: 협업 필터링과 콘텐츠 기반 추천 실습 목표를 안내합니다.
1	Code	환경 설정: <code>recommendation.yaml</code> 파일을 이용해 필요한 라이브러리를 설치합니다.
2	Markdown	[실습 1] 협업 필터링 (Surprise): MovieLens 데이터를 이용한 영화 추천 예제입니다.
3	Code	데이터 로드 및 학습: 1. <code>Surprise</code> 라이브러리의 데이터셋(MovieLens 100K)을 불러옵니다. 2. SVD(행렬 분해), KNN(유사도 기반) 등 다양한 알고리즘을 정의하고 학습시킵니다.
4	Code	성능 평가: 학습된 모델들의 RMSE(평균 제곱근 오차) 등을 계산하여 어떤 알고리즘이 평점을 가장 잘 맞추는지 비교합니다.
5	Markdown	[실습 2] 콘텐츠 기반 필터링: 텍스트 유사도를 이용한 상품 추천 예제입니다.
6	Code	데이터 준비 및 벡터화: 1. 상품 데이터(예: 전자제품 목록)를 데이터프레임으로 만듭니다. 2. <code>TfidfVectorizer</code> 를 사용해 상품명 텍스트를 숫자 벡터로 변환합니다.
7	Code	유사도 계산 및 추천: 1. 코사인 유사도(Cosine Similarity)를 계산해 상품 간의 거리를 측정합니다. 2. 특정 키워드(예: 'SSD')를 입력하면, 그와 가장 유사도가 높은 상품 5개를 찾아 출력합니다.

▼ 2. `3_recommendation_pipeline_01_content_based.ipynb` (콘텐츠 기반 추천 파이프라인)

이 파일은 **콘텐츠(텍스트)**를 분석하여 추천하는 시스템을 전문적으로 개발하는 파이프라인입니다. 단순히 TF-IDF만 쓰는 것이 아니라, LSA, PCA 같은 **차원 축소 기법**들을 적용해보며 어떤 방식이 가장 효율적이고 정확한지 비교 분석합니다.

- 주요 기능:

- 다양한 벡터화 기법 비교:

- 1. **TF-IDF:** 단어 빈도 기반의 가장 기본적인 방법.

- 2. **LSA (잠재 의미 분석):** 텍스트 속에 숨겨진 의미(주제)를 찾아 차원을 줄이는 방법.

3. PCA (주성분 분석): 데이터의 분포를 가장 잘 표현하는 축을 찾아 차원을 줄이는 방법.

- **군집화 평가:** K-means 클러스터링을 통해 각 방법이 비슷한 상품끼리 얼마나 잘 묶어주는지(군집 품질) 평가합니다.

순서	셀 종류	주요 내용 및 기능 설명
0	Markdown	노트북 소개: 콘텐츠 기반 추천 개발 파이프라인(전처리→벡터화→비교평가)을 안내합니다.
1	Markdown	[단계 1] 데이터 로드 및 전처리: 상품 리뷰 및 감정 분석 데이터를 준비합니다.
2-3	Code	데이터 로딩: 1. JSON 형태의 상품 감정 분석 데이터를 읽어 Pandas DataFrame으로 변환합니다. 2. 결측치 제거 및 텍스트 정제(특수문자 제거 등)를 수행합니다.
4	Markdown	[단계 2~4] 벡터화 모델 구축: 세 가지 다른 방식으로 텍스트를 벡터화합니다.
5-7	Code	모델 구현: 1. TF-IDF 모델: 텍스트를 고차원 벡터로 변환합니다. 2. LSA 모델: TF-IDF 결과에 SVD를 적용해 차원을 축소합니다(의미 기반). 3. PCA 모델: TF-IDF 결과에 PCA를 적용해 차원을 축소합니다(분산 기반).
8	Markdown	[단계 5] 품질 평가 (Clustering): 벡터화가 잘 되었는지 검증합니다.
9-10	Code	K-means & 실루엣 계수: 1. 각 벡터화 결과에 대해 K-means 군집화를 수행합니다. 2. 실루엣 계수(Silhouette Score)를 계산하여, 군집이 얼마나 명확하게 잘 나뉘었는지 수치로 평가합니다.
11	Markdown	[단계 6] 종합 비교: 어떤 기법이 가장 좋은지 결론을 내립니다.
12	Code	최종 리포트 출력: 1. TF-IDF, LSA, PCA의 장단점을 텍스트로 정리해 출력합니다. 2. 각 방법의 성능(실루엣 계수 등)을 표로 비교하고, 사용 시나리오별 권장 사항(예: "의미 파악이 중요하다면 LSA")을 제시합니다.

