



0108 Large Language Model

**1단계: 방대한
데이터로 사전 학습**



**2단계: 특정 목적에
맞게 미세 조정**



**3단계: 다음 단어
예측으로 문장 생성**

사과를 한 입 ()




LLM이 나오기 까지



LLM 개발 3단계



Pre-Training




Self Labeling


입력 (Input)	타겟 (Target/Label)
'the'	'cat'
'the cat'	'sat'
'the cat sat'	'on'
'the cat sat on'	'the'
'the cat sat on the'	'mat'

시대	데이터 크기	인간 레이블
전통적 머신러닝	메가바이트(MB)	필요
딥러닝 (ImageNet)	기가바이트(GB)	필요
GPT-2 시대	40 기가바이트(GB)	필요 없음


Pre-Training




SFT(Supervised Fine Tuning)




Open Source/Weight모델



대표적인 오픈 LLM 모델



Llama의 개념




LLM 실습 예제



실습 1: Llama 3.2를 활용한 질의 응답



- [Bilossom/llama-3.2-Korean-Bilossom-3B](#)
 - 150GB 정제된 한국어 데이터
 - Instruction tuning
- 질문/답변
- `top_p`, `top_k`, `temperature` 등 파라미터 설정



실습 2 : RAG를 활용한 질의 응답



- Model
 - [Blossom/llama-3.2-Korean-Blossom-3B](#)
- Vector Store
 - [ko-sbert-multitask](#)
 - Faiss(Facebook AI Similarity Search)
 - 10개의 문서를 임베딩


```

# 벡터 데이터
documents = [
    '대한민국은 동아시아 한반도 남부에 위치한 민주공화국이다.',
    '대한민국의 수도는 서울특별시이며, 인구 약 970만 명이다.',
    'K-POP은 한국 대중음악으로, BTS, 블랙핑크 등이 전 세계적으로 인기를 얻고 있다.',
    'K-드라마는 한국 드라마로, 오징어 게임,킹덤 등이 글로벌 히트를 기록했다.',
    '한국의 전통 음식으로는 김치, 비빔밥, 불고기 등이 있다.',
    '한국의 전통 스포츠로는 태권도와 씨름이 있다.',
    '한국의 주요 산업으로는 반도체, 자동차, 조선 산업이 발달하였다.',
    '삼성전자, LG전자, 현대자동차 등이 대표적인 글로벌 기업이다.',
    '정보통신기술(ICT) 강국으로 5G 네트워크 인프라가 세계 최고 수준이다.',
    '제주도는 한국 최대의 섬으로 한라산과 자연경관으로 유명하다.'
]
    
```



Retrieval Augmented Generation


RAG architecture




RAG에서 Embedding Model



1. 의미를 숫자로 압축



2. 의미가 가까운 정보 검색




Vector Store



비정형 데이터의 의미를 저장하는 AI 데이터베이스



Facebook AI Similarity Search



실습 3 : Fine-Tuning 실습



- 한국어 질의 응답 성능 향상을 목표
- [Blossom/llama-3.2-Korean-Blossom-3B](#)
- 4-bit 양자화
- LoRA
- SFTTrainer




KoAlpaca

- [Taegyu/KoAlpaca-v1.1a](https://github.com/Beomi/KoAlpaca)
- <https://github.com/Beomi/KoAlpaca>
- 네이버 지식인 베스트 질문 수집
- Stanford Alpaca의 52k개 데이터셋 기반


Alpaca 데이터셋은 다음과 같이 instruct 부분과 Input, 그리고 Output 부분으로 구성되어 있습니다.

```

{
  "instruction": "Describe a time when you had to make a difficult decision.",
  "input": "",
  "output": "I had to make a difficult decision when I was working as a project manager..."
},
{
  "instruction": "Identify the odd one out.",
  "input": "Twitter, Instagram, Telegram",
  "output": "Telegram"
}
    
```



Quantization



LLM이 양자화에 효과적인 이유




No Quantization



⚠ 정밀도 자체가 의미인 작업은 피하세요!!!

PEFT(Parameter Efficient Fine Tuning)


- 모델 전체 파라미터 대신 작은 모듈만 학습
- GPU 메모리 절약, 빠른 학습, 다중 태스크 전환 용이
- 베이스 모델 동결
- 소규모 모듈만 학습
- 대표 기법
 - LoRA
 - Prefix-Tuning
 - Adapters
 - PromptTuning



PEFT Adapters




Low-Rank Adaptation



QLoRA : AI 모델 튜닝의 새로운 표준



SFTrainer란?



실습 3 주의사항 : Llama 3.2 Fine-Tuning

- 5_llm_pipeline_01_qa.ipynb
- Cell 4 : LoRA Fine-tuning 설정 및 실행
- Optim을
 - paged_adamw_8bit을
 - adamw_torch으로 변경해야 함
- Win11, RTX 4050에서 커널크랙 발생

```
# =====
# Cell 4: LoRA Fine-tuning 설정 및 실행
# =====

from peft import LoraConfig
from trl import SFConfig, SFTrainer, DataCollatorForCompletionOnlyLM

# LoRA(Low-Rank Adaptation) 파라미터 설정
lora_config = LoraConfig(
    r=32, # 저차원 행렬의 rank (클수록 표현력 증가)
    lora_alpha=64, # 스케일링 팩터 (일반적으로 2*r)
    target_modules=['q_proj', 'k_proj', 'v_proj', 'o_proj', 'gate_proj'], # 과적합 방지용 드롭아웃
    lora_dropout=0.05, # 비어스 학습 비활성화
    bias='none', # 인과적 언어모델 태스크
    task_type='CAUSAL_LM'
)

# Fine-tuning 하이퍼파라미터 설정
training_args = SFConfig(
    output_dir='./korean-qa-lora', # 모델 저장 경로
    num_train_epochs=1, # 학습 에POCH 수
    per_device_train_batch_size=2, # 훈련 배치 크기
    per_device_eval_batch_size=2, # 평가 배치 크기
    gradient_checkpointing=True, # 메모리 절약을 위한 체크포인트링
    gradient_accumulation_steps=4, # 그라디언트 누적 단계
    optim='paged_adamw_8bit', # 8-bit Adamw 옵티마이저
    optim='adamw_torch', # 변경 주기
    logging_steps=10, # 첫 스텝 출력
    logging_first_step=True,
)
```

09. LLM : Llama 질의 응답 Fine-Tuning 결과

예제 파일

5_llm¥5_llm_pipeline_01_qa.ipynb (Colab용은 5_llm_pipeline_qa_colab.ipynb)

실행 결과

Cell 4 : LoRA Fine tuning

```
# 학습된 모델 저장
trainer.save_model("./korean-qa-lora")
tokenizer.save_pretrained("./korean-qa-lora")

print("모델 저장 완료!")
print("저장 위치: ./korean-qa-lora")

✓ 16m 31.7s

학습 설정 완료!
학습 데이터셋 최종 샘플 출력
{'messages': [{'content': '당신은 한국어 질문응답 전문가입니다. 주어진 문'}]}
{'messages': [{'content': '당신은 한국어 질문응답 전문가입니다. 주어진 문'}]}
No label names provided for model class 'PeftModelForCausalLM'. SIM
Fine-tuning 시작!
```

데이터셋 : KoAlpaca v1.1a 데이터셋

Cell 6 : 성능 평가 및 모델 평가

```
torch.cuda.empty_cache() # GPU 캐시 비우기

print("GPU 메모리 정리 완료!")
print(f"현재 GPU 메모리 사용량: {torch.cuda.memory_allocated() / 1024} MB")

✓ 5m 19.5s

평가 메트릭 정의 완료!
모델 평가 중...
0% | 0/10 [00:00<, ?it/s]
{'instruction': '일본의 일촌일품이란 정책은 무엇인가요?', 'output': '일촌'}
The following generation flags are not valid and may be ignored: ['1']
10% | 1/10 [00:28<04:12, 28.07s/it]The following generat

예측 원본: 일본의 "일촌 일품" 정책은 일본 정부가 1970년대 중반부터 추진한 정책이다.
1. **공공 투자**: 정부는 공공 투자를 증가시키고, 인프라 개발을 촉진했다.
저단 원본: 일촌일품은 일본 지방자치체들에서 각 지자체가 자선기
```

비고

실습 4 : 의료 도메인 특화 챗봇



- 의료 도메인으로 파인튜닝 된 LLM
 - [squarelike/llama2-ko-medical-7b](#)
- 한국어 의료 대화 데이터로 테스트 해보는 챗봇 파이프라인
 - [squarelike/ko_medical_chat](#)



09. LLM : 도메인 특화 결과

예제 파일

5_llm¥5_llm_exp.ipynb > Cell #8 (Colab용은 5_llm_exp_colab.ipynb)

실행 결과

- 수행 시간 단축을 위해 3 -> 1

```
# 데이터셋 샘플 테스트
def test_dataset_samples():
    print("\n데이터셋 샘플 테스트")
    print("-" * 40)

    if dataset is None:
        print("데이터셋을 사용할 수 없습니다.")
        return

    # 랜덤 샘플 3개 테스트
    indices = random.sample(range(len(dataset)), min(1, len(dataset)))

    for i, idx in enumerate(indices, 1):
        sample = dataset[idx]
        conversations = sample.get('conversations', [])

        if conversations:
```

```
print("\n모델 테스트:")
print(generate_medical_response('종상') 함수 사용)

# 사용 예시
# response = generate_medical_response("목이 아프고 기침이 나오")
# print(response)

✓ 10m 46.3s

사용 장치: cuda
모델 로드 중...

Loading checkpoint shards: 100% 2/2 [00:08<00:00, 4.12s/it]

Some parameters are on the meta device because they were offloaded to the cpu.
모델 로드 완료
의료 데이터셋 로드 중...
데이터셋 로드 완료: 3038개 샘플
한국어 의료 챗봇 예제
주요: 교육/연구 목적으로 실제 의료 진단을 대체할 수 없습니다.

데이터셋 샘플 테스트

테스트 1
환자 증상: 제 4세 아들은 과다활동에서 일정한 아이예요. 최근에 그의 가슴 중앙 아래에서 거의 바
```



비고

LLM 모델 : Llama 의료 분야 한글 데이터 사전학습 모델 (squarelike/llama2-ko-medical-7b)

실습 5 : 도메인 특화 Llama Fine-Tuning



- [Bllossom/llama-3.2-Korean-Bllossom-AICA-5B](#)
- Sponsored by AICA(AI융합아카데미)



실습 5 주의사항 : Llama 3.2 5B Fine-Tuning

- 5_llm_pipeline_02_domain.ipynb
- Windows 11, RTX 4050, 6GB



Cell 3 : 모델 로드 및 초기 설정

```
max_memory={0: "5.5GiB", "cpu": "32GiB"}

# 모델 로드 (양자화 적용)
print("모델 로딩 중... (몇 분 소요될 수 있습니다)")
model = MllamaForConditionalGeneration.from_pretrained(
    model_name,
    quantization_config=bnb_config,
    device_map="auto", # GPU 자동 할당
    torch_dtype=torch.float16, # 메모리 절약을 위한 half precision
    attn_implementation="eager",
    low_cpu_mem_usage=True, # CPU 메모리 절약
    offload_folder="./offload", # 디스크 오프로딩
    max_memory={0: "5.5GiB", "cpu": "32GiB"}
)
```



Cell 4 : LoRA Fine-tuning 설정 및 실행

```
optim="adamw_torch",

# SFT (Supervised Fine-Tuning) 학습 설정
training_args = SFTConfig(
    output_dir="./legal-chatbot", # 모델 저장 경로
    num_train_epochs=1, # 학습 에폭 수
    per_device_train_batch_size=1, # 배치 크기
    per_device_eval_batch_size=1, # 배치 크기
    gradient_checkpointing=True, # 메모리 절감
    gradient_accumulation_steps=8, # 그래디언트 누적
    optim="paged_adamw_8bit", # 최적화 알고리즘
    optim="adamw_torch",
    logging_steps=10, # 로깅 주기
    logging_first_step=True,
    logging_strategy="steps",
    logging_dir="./logs", # 로그 디렉토리
)
```

실습

[llm.zip](#)

6개의 파일은 **거대 언어 모델(LLM)**을 다루고 있으며, 크게 세 가지 주제로 분류됩니다. 파일명 뒤에 `_colab` 이 붙은 파일들은 코드는 동일하되 **Google Colab** 환경에서 실행하기 편하도록 최적화된 버전입니다.

따라서 기능별로 묶어서 **기초 체험(Exp)**, **질의응답 모델 개발(QA Pipeline)**, **도메인 특화 모델 개발(Domain Pipeline)** 세 단계로 나누어 설명해 드리겠습니다.

1. 5_llm_exp.ipynb & _colab

기능: LLM 기초 활용 및 RAG/프롬프트 엔지니어링 실습

이 파일은 모델을 학습시키지 않고, 이미 똑똑한 모델(Llama 3)을 가져와서 **잘 사용하는 방법**을 익히는 실습입니다. 특히, 모델이 모르는 외부 지식을 참고해서 답변하게 하는 **RAG(검색 증강 생성)** 기술과 특정 역할을 부여하는 **프롬프트 엔지니어링**을 다룹니다.

순서	셀 종류	주요 내용 및 기능 설명
0-1	Markdown/Code	실습 소개 및 설정: Llama 모델 활용 실습을 안내하고 필요한 라이브러리를 설치합니다.
2	Markdown	[실습 1] 기본 질의응답: Llama 모델을 불러와 대화를 시도합니다.
3	Code	모델 로드 및 추론: 1. Llama-3.2-Korean-Blossom 모델을 로드합니다. 2. "지구 온난화의 원인은?" 같은 질문을 던져 모델의 기본 답변 능력을 확인합니다.
4	Markdown	[실습 2] RAG (검색 증강 생성): LLM이 가지고 있지 않은 외부 문서를 참고해 답변하는 기술입니다.
5	Code	문서 검색 및 답변: 1. 회사 공지사항 같은 외부 텍스트 데이터 를 준비합니다. 2. 질문이 들어오면 관련 문서를 검색(Retrieval)합니다. 3. 검색된 내용을 프롬프트에 포함시켜 LLM에게 "이 내용을 참고해서 답변해"라고 요청합니다.
6	Markdown	[실습 3] 의료 상담 챗봇: 프롬프트를 조작해 특정 전문가 페르소나를 부여합니다.
7-8	Code	시스템 프롬프트 설정: 1. "당신은 친절한 의료 상담 AI입니다"라는 역할을 부여합니다. 2. 환자의 증상("머리가 아프고 열이 나요")을 입력하면, 의료진처럼 공감하고 조언하는 답변을 생성하는지 테스트합니다.

2. 5_llm_pipeline_01_qa.ipynb & _colab

기능: 질의응답(QA) 챗봇 Fine-Tuning 파이프라인

이 파일은 *****말 잘하는 비서*****를 만드는 과정입니다. 다양한 주제의 질문과 답변 쌍 (KoAlpaca 데이터셋)을 학습시켜, 모델이 사람의 지시를 잘 따르고 한국어로 자연스럽게 대답하도록 **재학습(Fine-Tuning)**시키는 전체 과정을 담고 있습니다.

순서	셀 종류	주요 내용 및 기능 설명
0-1	Markdown	노트북 소개: 일반적인 질의응답 능력을 키우는 파이프라인 (전처리→튜닝→평가)을 안내합니다.
2	Code	데이터셋 준비 (KoAlpaca): 1. 한국어 지시 튜닝 데이터셋인 KoAlpaca 를 로드합니다. 2. 질문(Instruction)과 답변(Output)을 모델 학습용 형식으로 변환합니다.
3	Code	모델 및 LoRA 설정: 1. 거대 모델을 효율적으로 학습하기 위해 LoRA(Low-Rank Adaptation) 기술을 적용합니다. 2. 모델의 모든 파라미터를 수정하는 대신, 일부만 수정하여 메모리를 아끼고 속도를 높입니다.
4	Code	학습 (Fine-Tuning): 1. 준비된 데이터로 모델 훈련(Trainer.train)을 시작합니다. 2. 학습이 진행되면서 손실값(Loss)이 줄어드는 것을 확인합니다.
5	Markdown	[단계 2] 성능 평가: 학습된 모델이 얼마나 말을 잘하는지 채점합니다.
6	Code	ROUGE 점수 평가: 1. 테스트 질문에 대해 모델이 생성한 답변과 정답을 비교합니다. 2. 단어가 얼마나 겹치는지(ROUGE Score)를 계산하여 모델의 언어 능력을 수치화합니다.

3. **5_llm_pipeline_02_domain.ipynb** & **_colab**

기능: 도메인 특화(법률) 챗봇 Fine-Tuning 파이프라인

이 파일은 *****법률 전문가 AI*****를 만드는 과정입니다. 일반적인 대화가 아니라, **민사법**과 같은 전문 지식이 필요한 영역의 데이터를 집중적으로 학습시켜, 법률 용어를 이해하고 정확한 법적 조언을 할 수 있도록 튜닝합니다.

순서	셀 종류	주요 내용 및 기능 설명
0-1	Markdown	노트북 소개: 특정 분야(법률)에 강한 챗봇을 만드는 개발 과정을 안내합니다.
2	Code	도메인 데이터 준비: 1. AI Hub 민사법 데이터셋 을 로드합니다.

		2. 법률 질문과 판례/답변 데이터를 학습 모델이 이해하기 쉬운 형태로 가공합니다.
3-4	Code	모델 학습 (Legal Knowledge): 1. 이전 파일과 마찬가지로 LoRA를 사용하지만, 이번에는 법률 데이터 를 주입합니다. 2. 모델이 "손해배상", "채무불이행" 같은 전문 용어와 맥락을 익히도록 훈련합니다.
5	Code	전문가 답변 테스트: 1. "계약 해제 시 손해배상 청구가 가능한가?" 같은 법률 질문 을 던집니다. 2. 학습된 모델이 법적 근거를 들어 논리적으로 답변하는지 확인합니다.
6	Code	법률 개체명 인식 (선택): 답변 내에서 중요한 법률 용어 (entity)를 따로 추출하거나 강조하는 기능을 테스트합니다.

요약하자면:

- **파일 1 (Exp):** 모델을 훈련 없이 **도구처럼 사용해**보는 실습 (RAG, 챗봇 만들기).
- **파일 2 (Pipeline 01):** 모델에게 *****말하는 법*****을 가르치는 과정 (일반 대화 능력 향상).
- **파일 3 (Pipeline 02):** 모델에게 *****전문 지식*****을 가르치는 과정 (법률 전문가 만들기).

이 파일들을 통해 LLM을 단순히 사용하는 것부터, 나만의 목적에 맞게 튜닝하는 고급 기술까지 단계별로 익히실 수 있습니다.